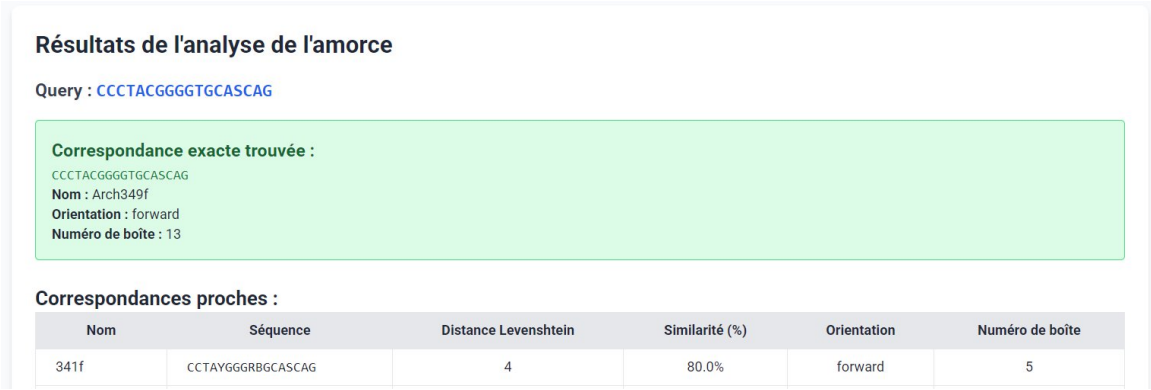
Problématique : Les couples de primers Arch349f806r et 341f785r amplifient tous les deux la même région du gène 16s des prokaryotes (V3V4) comme la séquence amplifiée par 341f785r est légèrement plus courte que celle d'Archée, lors de la séparation des données via les primers une partie des données archée se retrouvent dans le jeu de données bactérien, le but de cette analyse et de trouver une méthode d'analyse pour mieux séparer les données, et de montrer l'intérêt de l'utilisation du marqueur ARCH en parallèle du marqueur Bact.

Différence entre les primers Arch et Bact

Comparaison Marqueur Arch forward avec Marqueur Bact forward :



Résultats de l'analyse de l'amorce

Query : CCCTACGGGGTGCASCAG

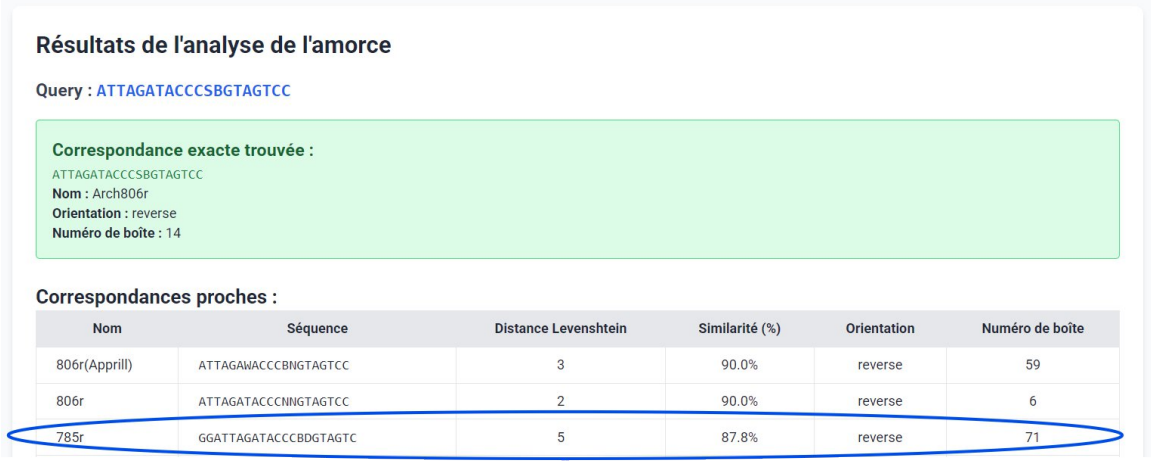
Correspondance exacte trouvée :
CCCTACGGGGTGCASCAG
Nom : Arch349f
Orientation : forward
Numéro de boîte : 13

Correspondances proches :

Nom	Séquence	Distance Levenshtein	Similarité (%)	Orientation	Numéro de boîte
341f	CCTAYGGGRBGCASCAG	4	80.0%	forward	5

Une similarité de 80 % et une distance de Levenshtein de 4 signifient qu'il faut quatre opérations (insertions, suppressions ou substitutions) pour transformer la séquence du primer forward archée en primer forward bactérie. Cela montre que les deux amorces sont très proches.

Comparaison Marqueur Arch reverse avec Marqueur Bact reverse



Résultats de l'analyse de l'amorce

Query : ATTAGATACCCSBGTAGTCC

Correspondance exacte trouvée :
ATTAGATACCCSBGTAGTCC
Nom : Arch806r
Orientation : reverse
Numéro de boîte : 14

Correspondances proches :

Nom	Séquence	Distance Levenshtein	Similarité (%)	Orientation	Numéro de boîte
806r(Apprill)	ATTAGAWACCCBNGTAGTCC	3	90.0%	reverse	59
806r	ATTAGATACCCNNGTAGTCC	2	90.0%	reverse	6
785r	GGATTAGATACCCBDGTAGTC	5	87.8%	reverse	71

Une similarité de 80 % et une distance de Levenshtein de 4 signifient qu'il faut quatre opérations (insertions, suppressions ou substitutions) pour transformer la séquence du primer reverse archée en primer reverse bactérie. Cela montre que les deux amorces reverse sont très proches.

Cette proximité entre les deux couples d'amorces révèle une forte similarité. Le couple d'amorces "Arch" se distingue principalement par l'utilisation de bases plus spécifiques, ce qui, selon l'auteur, permet de mieux cibler les archées au détriment des autres organismes procaryotes.

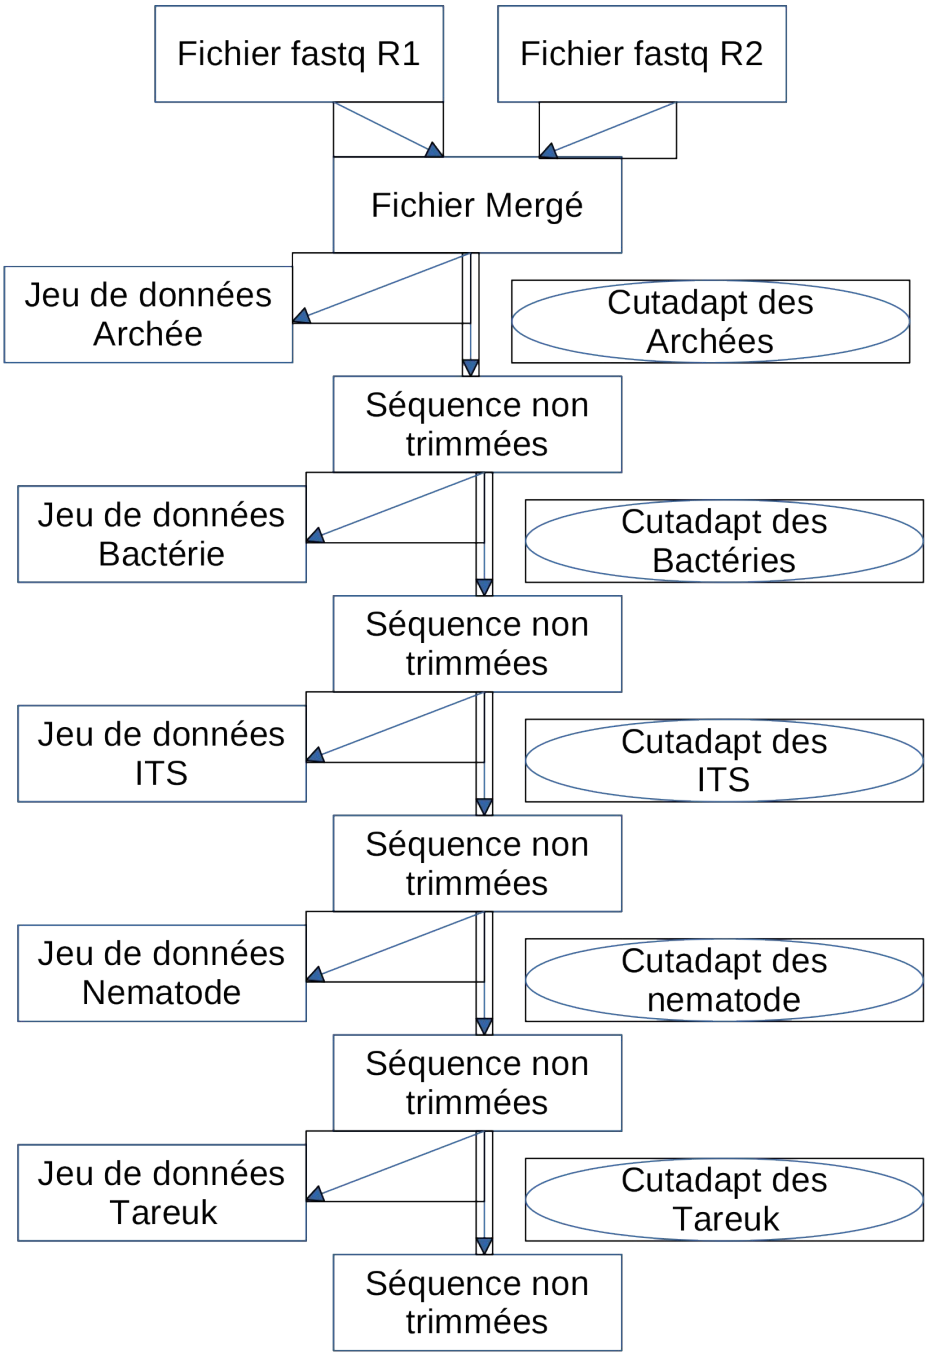
En raison de la forte similarité entre ces amorces, il est nécessaire d'affiner les paramètres de détection lors de l'étape de "cutadapt", en imposant par exemple une tolérance minimale de quatre différences nucléotidiques. Cela permettrait de mieux discriminer les séquences amplifiées par des amorces proches.

Analyse de données Pre-Process

Les données ont été assemblées à l'aide du logiciel FLASH [1], en utilisant un overlap minimum de 10 pb et maximum de 250 pb. Seules les séquences correctement assemblées ont été retenues pour l'analyse. Un trimming des primers a ensuite été effectué avec le logiciel Cutadapt [2], en appliquant les paramètres suivants : séquences forward et reverse renseignées en 5'-3', option --no-trim activée afin de ne pas supprimer les amorces si elles sont détectées, option --untrimmed-output utilisée pour enregistrer séparément les séquences ne contenant pas d'amorces, et un error-rate fixé à 0.01, ce qui équivaut à une correspondance parfaite avec les séquences d'amorce. À partir des fichiers d'assemblage, cinq jeux de données distincts ont été générés successivement, en filtrant à chaque étape les séquences correspondant à une paire d'amorces spécifique sans conserver les données de l'amorce précédente. Dans le but de ne pas avoir des données répétées entre les séquences issues des primers Archée et des primers Bactérie. Voir tableau et la figure ci-dessous pour l'ordre et les séquences. Chaque jeu de données a ensuite été analysé à l'aide du pipeline FROGS en conservant la méthodologie associée au MAT&MET de l'analyse bioinformatique à la seule différence que dans le pré-process nous précisons que les séquences sont déjà mergées en amont de l'analyse.

Séquences des amorces utilisées pour les différentes PCR (sens et antisens)

Nom	Forward (5'-3')	Reverse (5'-3')
Arch349f_806r	CCCTACGGGGTGCASCAG	ATTAGATACCCSBGTAGTCC
341f785r	CCTAYGGGRBGCASCAG	GGATTAGATACCCBDGTAGTC
ITS86_ITS4	GTGAATCATCGAATCTTTGAA	GCATATCAATAAGCGGAGGA
nematodeF548_R1912	AGAGGGCAAGTCTGGTGCC	CCCTAGTTCTGACCGTAAA
TAReuk	CCAGCASCYGCGGTAATTCC	TYRATCAAGAACGAAAGT



Explication du traitement de données avant analyse avec le pipeline FROGS

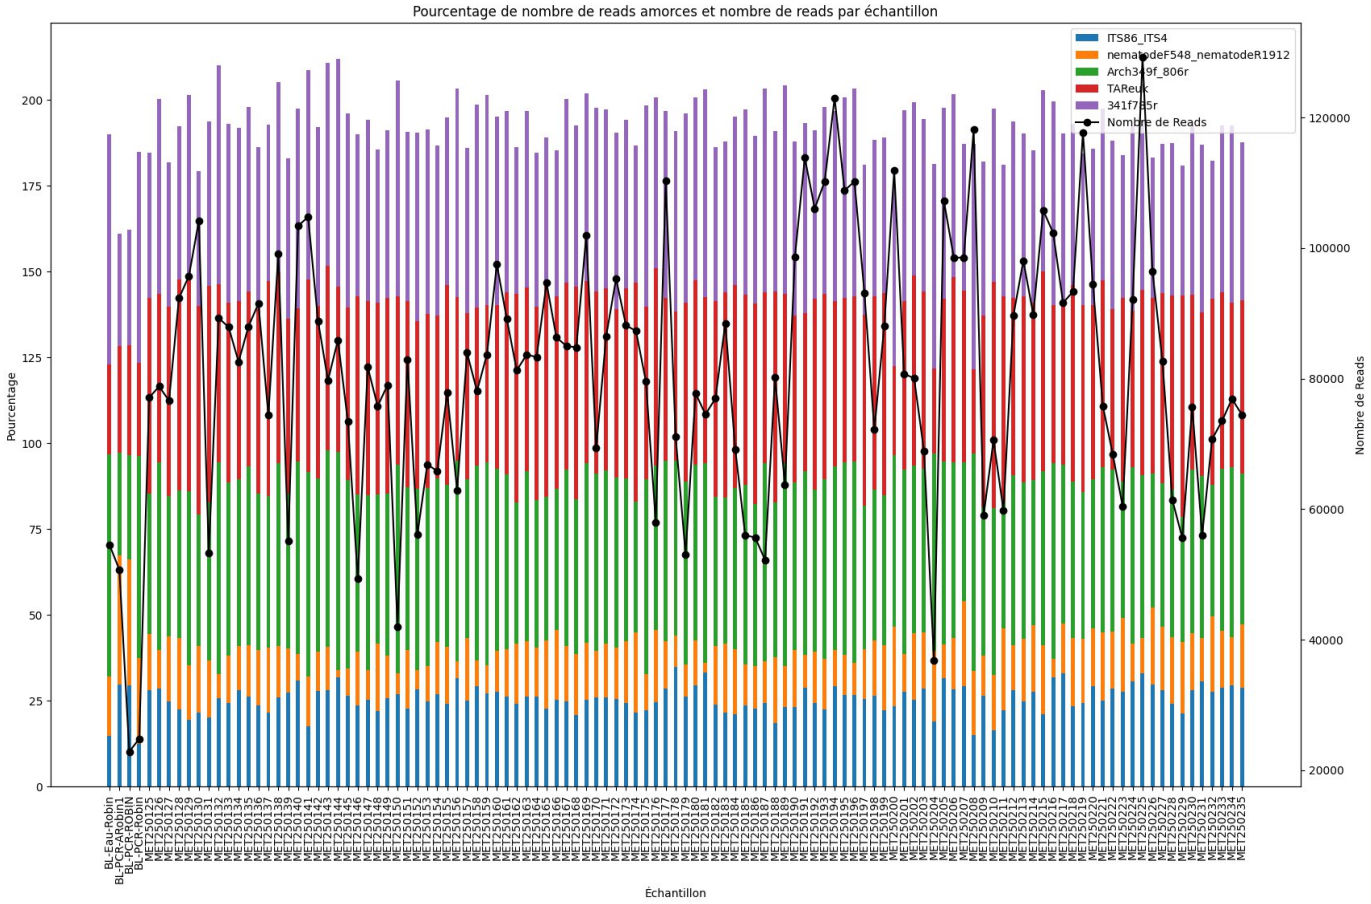
Résultats du cutadapt des primers

Le décompte du nombre d'amorce pour chaque couple d'amorce est disponible dans le fichier "decompte.csv".

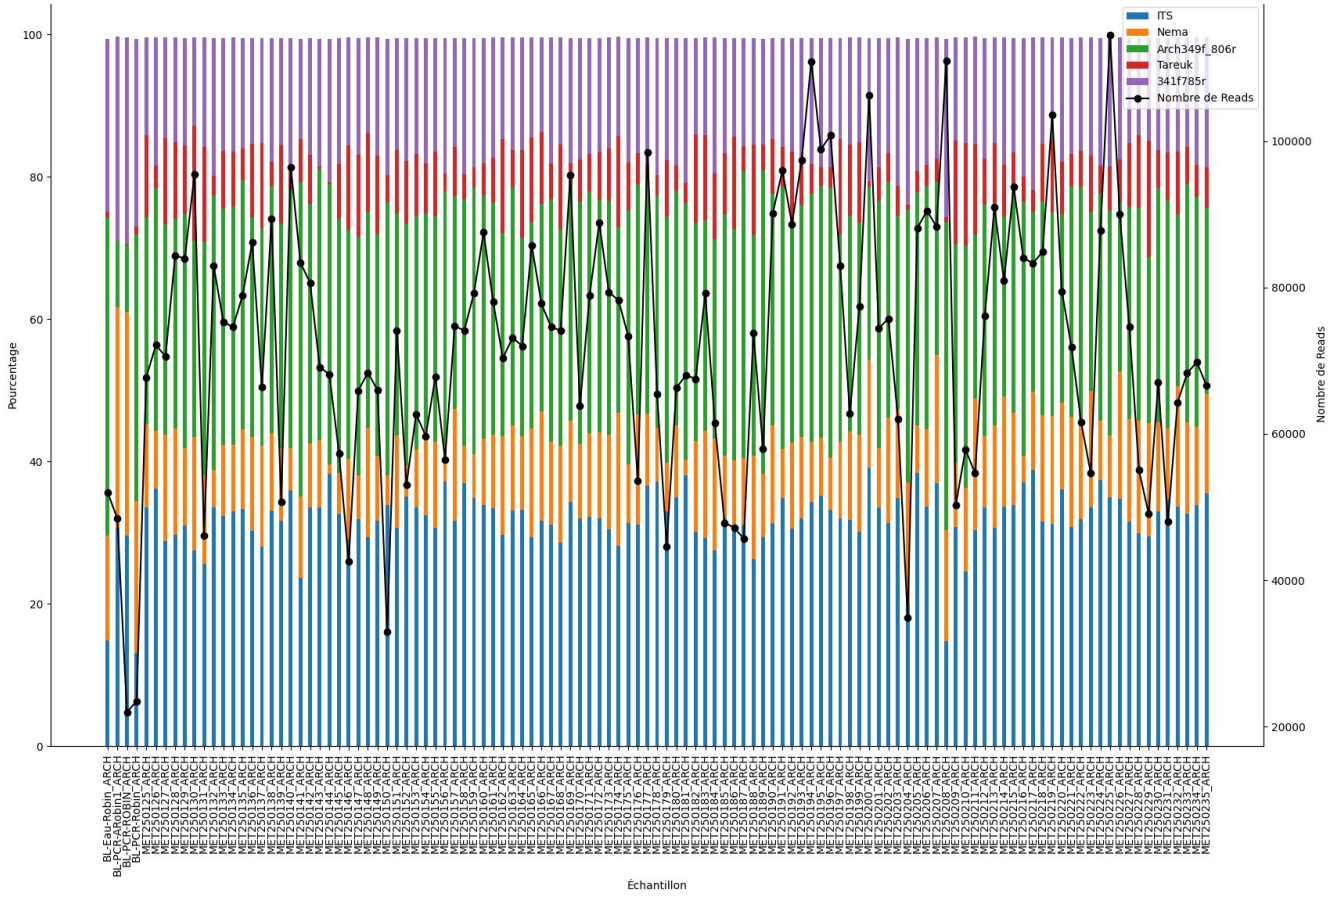
En comparant les graphiques « Répartition des reads avant pre-process » et « Répartition des reads après pre-process », il apparaît que, dans le premier cas, la somme des séquences assignées par *cutadapt* à chaque couple d'amorces dépasse le nombre total de reads fusionnés (*merged*). Cela suggère qu'une fraction des reads est associée à plusieurs marqueurs simultanément, indiquant un chevauchement entre certains couples d'amorces.

En revanche, dans le second graphique, la somme des reads assignés par *cutadapt* correspond en moyenne à 99,50 % des séquences fusionnées pour chaque échantillon. Ce résultat démontre la pertinence et la robustesse de la méthode utilisée pour séparer les jeux de données, puisqu'il est possible d'attribuer quasi intégralement les reads fusionnés à un seul couple d'amorces.

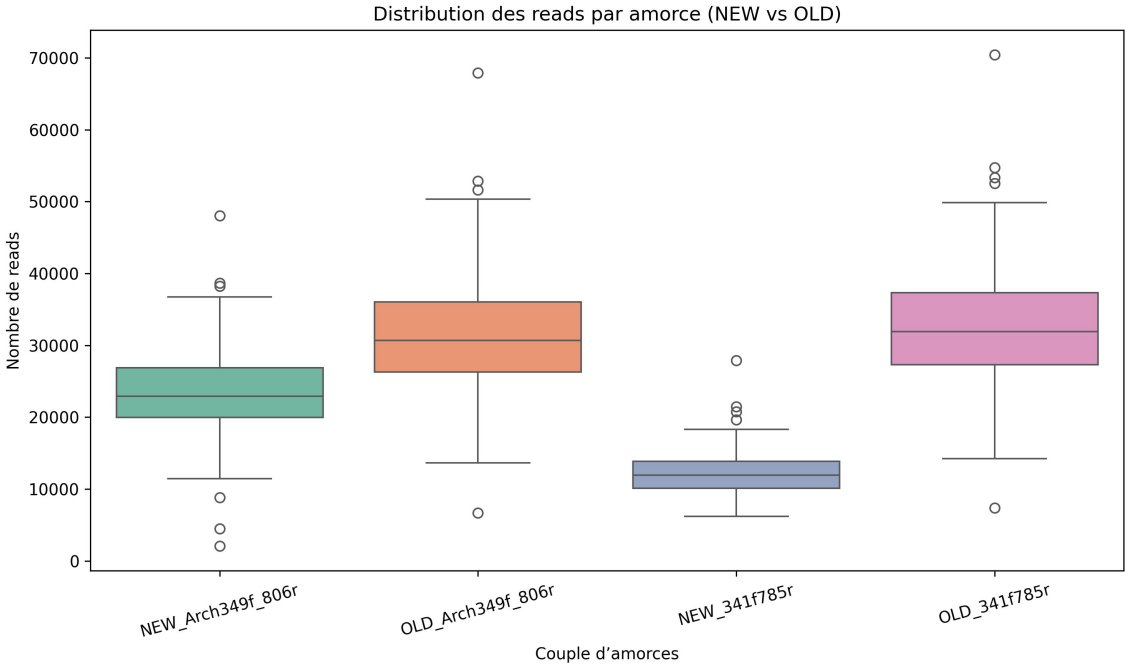
<u>Répartitions des reads avant pre-process :</u>



Répartition des reads après pré-process :



Dans les cas spécifiques de la comparaison des archées et des bactéries a été réalisé un graphique « boxplot » comparant le nombre de séquence trimés avec les marqueurs Archées et Bactéries avant et après le pré-process.



L'analyse du graphique montre qu'avec l'ancienne méthode ("OLD"), le nombre de lectures ("reads") par échantillon présente une répartition similaire entre les deux amorces, avec une médiane avoisinant les 35 000 lectures et un écart interquartile comparable.

En revanche, avec la nouvelle méthode ("NEW"), une différence nette apparaît : les données issues de l'amorce spécifique aux archées (NEW_Arch349f_806r) présentent une médiane autour de 23 000 lectures, tandis que les données obtenues avec l'amorce bactérienne (NEW_341f785r) affichent une médiane d'environ 12 000 lectures.

Le nombre de read median entre la premiere analyse (OLD) et la seconde (NEW) démontrent une complémentarité des amorces archae et bactéries : la somme des reads archae (NEW) et bactéries (NEW) correspond à la combinaison de deux marqueurs (archae et bacterie OLD).

Ces observations mettent en évidence l'intérêt d'utiliser un marqueur archéen spécifique en complément du marqueur bactérien généraliste. En effet, cela permet non seulement d'apporter un volume supplémentaire de données, mais également de mieux cibler la diversité archéenne.

Références

[1] FLASH: Fast Length Adjustment of Short reads to improve genome assemblies.
[2] Cutadapt removes adapter sequences from high-throughput sequencing reads.