Date : 04/09/2023
CONFIDENTIEL
Pascal ALONSO
Julien THOUIN

Présentation méthodologie de l'analyse bioinformatique

Il existe plusieurs pipelines d'analyses bio-informatiques pour l'analyse des données générées par la métagénomique ciblée (FROGS (Escudié et al., 2017), QIIME (Caporaso et al., 2010), MOTHUR (Schloss et al., 2009)). Ces pipelines reposent tous sur les mêmes principes de tri, de nettoyage et de simplification des données issues du séquençage. En voici une présentation des principales étapes. Le pipeline utilisé pour votre projet et le pipeline FROGS (Escudié et al., 2017).

Démultiplexage

Le démultiplexage a pour but de réattribuer toutes les séquences à leurs échantillons d'origine. Une recherche des barres codes est réalisée pour toutes les séquences afin obtenir des listes de séquences par échantillon. Le démultiplexage est réalisé par le logiciel interne d'Illumina.

Preprocessing

Le preprocessing a pour but de fusionner les lectures sens et antisens et d'éliminer les séquences de mauvaise qualité. Nous avons utilisé pour l'assemblage des lectures sens et antisens l'outil VSEARCH v2.9.1 et utilisé les commandes fastq_mergepairs et l'option fastq_allowmergestagger. Les amorces des cibles de bactéries et de champignons sont recherchées et éliminées avec l'outil cutadapt v4.1 autorisant un match partiel sur 2/3 de la longueur des amorces. Seules les séquences dont la longueur est celle attendu et contenant les amorces sens et antisens sont conservées. Les séquences trop courtes qui ne peuvent pas permettre la fusion des séquences sens et antisens et les lectures trop longues qui sont potentiellement des chimères sont supprimées. Les séquences contenant trop de bases dégénérées indiquent une mauvaise qualité de lecture sont aussi écartées de l'analyse avec l'outil VSEARCH et la commande fastq_filter option eeout.

Enfin, une étape de déréplication permet de diminuer le nombre de séquences à manipuler en ne gardant qu'un seul exemplaire de toutes les séquences identiques, ce qui permet d'accélérer les calculs des étapes suivantes. La déréplication a été réalisée avec la commande derep_fulllength de l'outil VSEARCH.

Clustering

Il existe plusieurs méthodes de clustering (aussi appelé débruitage - denoising). Le principe repose sur la réduction du nombre de séquences à traiter en corrigeant le bruit introduit dans les fragments séquencés ou en agglomérant les séquences proches. En effet, pour corriger différents biais techniques (erreurs de la polymérase lors de la PCR ou erreur de séquençage) qui génèrent de la diversité, le clustering des séquences permet de regrouper les séquences qui ont une forte identité pour ne conserver qu'une séquence représentative de tous les variants (souvent la plus abondante du cluster). Pendant longtemps, le seuil d'identité de 97% proposé par Stackebrandt et Goebel en 1994 (STACKEBRANDT & GOEBEL, 1994) permettait de différentier les différentes espèces microbiennes (Schloss & Handelsman, 2005, Seguritan &

Rohwer, 2001, Westcott & Schloss, 2017). Ce seuil de 97% jugé comme arbitraire a été remplacé par plusieurs autres algorithmes de clustering (Edgar, 2018, Zou et al., 2018). La méthode que nous avons utilisé pour votre projet est appelée Swarm v2.1.10 (Mahe et al., 2015). La méthode d'agrégation des séquences développée dans l'algorithme SWARM v2 permet de regrouper des séquences, non pas à partir d'un seuil d'identité, mais en agrégeant progressivement les séquences qui ont une différence nucléotidique entre elles tant que leurs abondances sont décroissantes (Figure 1). Il est supposé par l'algorithme de calcul SWARM v2 que les séquences avec des erreurs de séquençages ne peuvent pas être plus abondantes que la séquence d'origine (Mahe et al., 2015). Les clusters formés sont appelés unités taxonomiques opérationnelles (OTUs) (Moyer et al., 1994). Seule la séquence la plus abondante des clusters est conservée. Elle est considérée comme représentative de la diversité de l'ensemble des séquences du cluster. Le paramétrage du clustering a une forte influence sur le nombre final d'OTUs et conditionne les indices de richesse des communautés microbiennes. Le clustering réduit fortement le nombre de séquences tout en conservant l'information d'abondance de celles-ci et rend possible l'assignation taxonomique qui était impossible à réaliser directement sur les séquences obtenues, en raison de leurs trop grands nombres. Les séquences unique, c'est-à-dire présente dans un seul échantillon et observé seulement une fois dans ce même échantillon sont supprimées. Ces séquences sont peu fiables, alourdisses l'analyses et non aucun poids statistique dans les analyses de diversité.

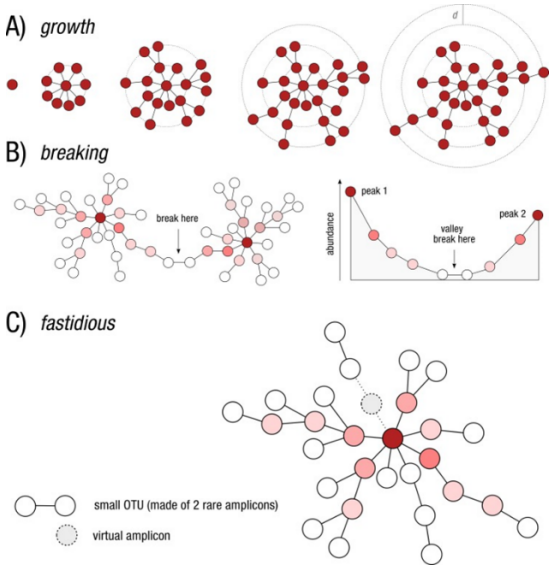


Figure 1 : Vue schématique de l'approche de clustering des séquences Swarm v2. (A) Swarm v2 regroupe les séquences de manière itérative en utilisant un petit seuil local « d » choisi par l'utilisateur, permettant aux OTUs de se développer jusqu'à leurs limites naturelles, où aucune autre séquence ne peut être ajoutée avec le seuil « d ». (B) Swarm v2 prend en compte l'abondance de chaque séquence. Plus le rouge est foncé, plus l'abondance est élevée. Le clustering des séquences en grappes est défini en ne permettant pas une augmentation de l'abondance dans le clustering des séquences. L'algorithme SWARM v2 estime que les erreurs de séquençage ne peuvent pas produire des séquences plus abondantes que leurs séquences d'origines. (C) L'option fastidieuse évite les sous-groupes (par exemple, la production de petites OTUs tels que les singletons et les doubletons) en postulant l'existence d'amplicons virtuels de liaison pour greffer les petites OTUs sur les plus grands (Mahe et al., 2015).

Déchimérisation

L'amplification PCR est connue pour introduire des erreurs ponctuelles de séquences, et pour produire des séquences chimériques (Wang & Wang, 1996). Les chimères sont des hybrides de deux (ou plus) séquences. Leurs formations sont liées à l'hybridation de deux séquences différentes au cours de l'étape d'élongation de la PCR. Les chimères sont séquencées comme tous les autres amplicons. Les chimères sont des sous-produits de PCR et ne constituent que des OTUs de faibles abondances, pouvant cependant représenter une part très importante du nombre d'OTUs (Bonder et al., 2012, Bachy et al., 2013). Les chimères ont été éliminées via l'outil VSEARCH et la commande, uchime_denovo.

La déchimérisation *de novo* estime que les séquences qui ont permis la formation des chimères sont toujours plus abondantes que les séquences de la chimère formée. Les chimères sont détectées suite à un alignement de toutes les séquences d'un même échantillon. Les séquences identifiées comme mosaïques, c'est-à-dire qui contiennent des alignements partiels de plusieurs séquences, dont les séquences d'origine sont toutes plus abondantes, sont éliminées.

Assignation taxonomique

Après toutes ces étapes de nettoyage et de décomplexification des données, les séquences OTUs sont annotées en recherchant des séquences similaires dans les bases de données de référence via des recherches de similarités par l'algorithme BLAST (Altschul et al., 1990). Pour les séquences d'origine bactérienne de type 16S ou eucaryote de type 18S, la base de donnée SILVA est utilisée et pour les séquences d'origine fongique la base de donnée UNITE.

Traitement bio-informatique et statistique sur les tables d'OTUs

Les table d'OTUs générée à la suite du pipeline FROGS sont traitées sous R v4.3.1 avec le package Phyloseq v1.44.0 pour normaliser les données et analyser la diversité des communautés microbiennes.
La normalisation des profondeurs de séquençages a été réalisée par raréfaction (sous échantillonnage aléatoire des séquences pour chaque échantillon, le nombre de séquences échantillonnées correspond à l'échantillon avec la plus faible profondeur de séquençage).

Calcul des indices de diversité et test des variables suivies comme facteurs de structuration des communautés microbienne

Les calculs des indices de diversité α, richesse spécifique et indice de Shannon, ont été réalisés avec le package Phyloseq pour R. Un test de Tukey sur les valeurs de diversité α a été réalisé afin de déterminer si des différences significatives existaient entre les communautés bactériennes, fongiques et eucaryotes pour chaque variable suivi. L'analyse des variations de composition des communautés microbiennes entre échantillons (diversité β) basée sur le calcul des distances de Bray-Curtis et Jaccard sont réalisées avec le package Vegan pour R. Elle est basée sur une analyse de la variance par permutation (PERMANOVA) et par une analyse en coordonnées principales (PCoA).

Références :

Altschul SF, Gish W, Miller W, Myers EW, Lipman DJ, 1990. Basic local alignment search tool. *J Mol Biol* **215**, 403-10.

Bachy C, Dolan JR, López-García P, Deschamps P, Moreira D, 2013. Accuracy of protist diversity assessments: morphology compared with cloning and direct pyrosequencing of 18S rRNA genes and ITS regions using the conspicuous tintinnid ciliates as a case study. *The ISME journal* **7**, 244-55.

Bonder MJ, Abeln S, Zaura E, Brandt BW, 2012. Comparing clustering and pre-processing in taxonomy analysis. *Bioinformatics* **28**, 2891-7.

Caporaso JG, Kuczynski J, Stombaugh J, *et al.*, 2010. QIIME allows analysis of high-throughput community sequencing data. *Nat Methods* **7**, 335-6.

Edgar RC, 2018. Updating the 97% identity threshold for 16S ribosomal RNA OTUs. *Bioinformatics* **34**, 2371-5.

Escudié F, Auer L, Bernard M, *et al.*, 2017. FROGS: Find, Rapidly, OTUs with Galaxy Solution. *Bioinformatics* **34**, 1287-94.

Mahe F, Rognes T, Quince C, De Vargas C, Dunthorn M, 2015. Swarm v2: highly-scalable and high-resolution amplicon clustering. *PeerJ* **3**, e1420.

Moyer CL, Dobbs FC, Karl DM, 1994. Estimation of diversity and community structure through restriction fragment length polymorphism distribution analysis of bacterial 16S rRNA genes from a microbial mat at an active, hydrothermal vent system, Loihi Seamount, Hawaii. *Applied and Environmental Microbiology* **60**, 871-9.

Mysara M, Saeys Y, Leys N, Raes J, Monsieurs P, 2015. CATCh, an Ensemble Classifier for Chimera Detection in 16S rRNA Sequencing Studies. *Applied and Environmental Microbiology* **81**, 1573-84.

Schloss PD, Handelsman J, 2005. Introducing DOTUR, a Computer Program for Defining Operational Taxonomic Units and Estimating Species Richness. *Applied and Environmental Microbiology* **71**, 1501-6.

Schloss PD, Westcott SL, Ryabin T, *et al.*, 2009. Introducing mothur: Open-Source, Platform-Independent, Community-Supported Software for Describing and Comparing Microbial Communities. *Applied and Environmental Microbiology* **75**, 7537-41.

Seguritan V, Rohwer F, 2001. FastGroup: A program to dereplicate libraries of 16S rDNA sequences. *BMC Bioinformatics* **2**, 9.

Stackebrandt E, Goebel BM, 1994. Taxonomic Note: A Place for DNA-DNA Reassociation and 16S rRNA Sequence Analysis in the Present Species Definition in Bacteriology. *International Journal of Systematic and Evolutionary Microbiology* **44**, 846-9.

Wang GCY, Wang Y, 1996. The frequency of chimeric molecules as a consequence of PCR co-amplification of 16S rRNA genes from different bacterial species. *Microbiology* **142**, 1107-14.

Westcott SL, Schloss PD, 2017. OptiClust, an Improved Method for Assigning Amplicon-Based Sequence Data to Operational Taxonomic Units. *mSphere* **2**, e00073-17.

Zou Q, Lin G, Jiang X, Liu X, Zeng X, 2018. Sequence clustering in bioinformatics: an empirical study. *Briefings in Bioinformatics* **21**, 1-10.